

Relatório Lab02 - Assistentes de IA vs. Codificação Manual

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab02 - Assistentes de IA vs. Codificação Manual
Grupo (trio)	Tiago Boaventura · Kayque Allan · João Filardi
Link do repositório / GitHub Projects	https://github.com/JoaoFilardi/LabExperimentacao
Data de entrega	23/09/2026

1. Introdução

Este laboratório avalia, por meio de um experimento controlado crossover within-subject, o efeito de um assistente de IA generativa (GitHub Copilot) na resolução de katas de programação, seguindo o método GQM (Basili et al., 1994): comparar IA vs. codificação manual quanto a tempo, defeitos e qualidade estrutural.

RQ1 (Tempo): IA reduz o time-to-green? $H_1: \text{Mediana}(T_{IA}) < \text{Mediana}(T_{Manual})$.

RQ2 (Defeitos): IA eleva a taxa de sucesso nos testes? $H_2: \text{Mediana}(SR_{IA}) > \text{Mediana}(SR_{Manual})$.

RQ3 (Estrutura): IA altera a complexidade ciclomática (CC) ou volume (LOC/SLOC)? $H_3: \text{Mediana}(CC \text{ ou } LOC)_{IA} \neq \text{Manual}$.

Além do exigido, o grupo acrescentou o Índice de Manutenibilidade (MI), a densidade CC/SLOC e o tamanho de efeito (r de Rosenthal e Cliff's Delta) como métricas de apoio à RQ3 (detalhado em 3.6).

2. Contexto

Lab02 do semestre. Objeto de estudo: 12 trials (3 integrantes $\times$ 4 katas autorais de dificuldade equivalente), metade resolvidos manualmente e metade com IA, em ordem contrabalanceada, sob time-box de 35 min. Base teórica: GQM (Basili et al., 1994), McCabe (1976) para complexidade ciclomática e teste de Wilcoxon (1945) como análise inferencial não paramétrica pareada, adequada ao N pequeno do desenho within-subject.

3. Metodologia

Resumo dos desafios, decisões, processo, ferramentas e métricas do experimento.

3.1 Principais Desafios

- **Logs inconsistentes:** parte dos trials estava com identificador genérico (sessão-copilot) ou sobrescrita em commits - resolvido com auditoria e recálculo determinístico via Radon 6.0.1.
- **Rastreabilidade por integrante:** catalogação manual dos arquivos em katas/joão, katas/tiago, katas/kayque para garantir 12 observações pareadas (6 Manual / 6 IA).
- **Censura de tempo:** trials sem sucesso aos 35 min precisam ser fixados em 35.0 min (não descartados) para evitar viés de sobrevivência.

3.2 Tomadas de Decisão


- Mediana e IQR (não média/desvio-padrão) como medida central, dado N pequeno (4 katas / 12 trials).
- Teste de Wilcoxon Signed-Rank pareado por kata, com r de Rosenthal e Cliff's Delta como tamanho de efeito, já que p-valor sozinho é pouco informativo com N=4.
- SLOC como métrica de controle obrigatória ao lado de CC, para não confundir 'menos complexo' com 'código truncado'.

3.3 Etapas

Sprint	Entregas
Lab02S01	Desenho experimental (GQM, hipóteses, matriz crossover), 4 katas autorais, scripts de tempo e de métricas estáticas.
Lab02S02	Execução dos 12 trials (3 integrantes × 4 katas, 6 Manual/6 IA) e coleta de logs.
Lab02S03	Análise inferencial (Wilcoxon) para RQ1–RQ3 + dashboard (Pandas/Matplotlib/Seaborn).
Relatório Final	Este documento, com resultados e discussão hipótese × resultado.

Configuração do processo

Cada trial foi registrado como Issue individual no GitHub Projects (Assignee - integrante responsável), com commits referenciando o número da Issue.



3.4 Ferramentas

- Python 3.14/3.11 + pytest - execução dos katas e suíte de aceitação (4 testes/kata).
- GitHub Copilot - assistente de IA padronizado em todos os trials do Tratamento B.
- Radon 6.0.1 (cc, raw, mi) - complexidade ciclomática, SLOC/LOC e índice de manutenibilidade.
- scipy.stats.wilcoxon - teste de postos com sinais, pareado por kata.
- Pandas + Matplotlib/Seaborn - dashboard consolidado (gráficos dashboard/).
- GitHub Projects (v2) - Kanban do grupo, 1 Issue por trial.

3.5 Tabela de Métricas

RQ	Métrica	Definição Operacional	Unidade	Ferramenta / Fonte
RQ1	Time-to-green (T_TTG)	Minutos até 100% dos testes, censura em 35 min	min	Cronômetro / log do trial
RQ2	Taxa de sucesso (SR)	$(\text{testes aprovados} / \text{total}) \times 100$ ao fim do time-box	%	pytest
RQ3-CC	Complexidade ciclomática média	McCabe, média por função/método	inteiro	Radon cc
RQ3-SLOC/LOC	Volume de código	Linhas executáveis (SLOC) e totais (LOC)	linhas	Radon raw
RQ3-MI	Índice de Manutenibilidade	Composto (CC + LOC + Halstead)	0–100	Radon mi

3.6 Inovações Propostas pelo Grupo

- **Densidade CC/SLOC** (complexidade por linha) - não pedida pelo enunciado, usada para verificar se a IA concentra mais ou menos bifurcações por linha escrita.
- **Tamanho de efeito (r de Rosenthal e Cliff's Delta)** ao lado do p-valor de Wilcoxon, essencial com N=4 pares, onde o p-valor mínimo possível já é 0,0625–0,25.

4. Resultados

4.1 Coleta de Dados

12 trials completos e auditados (3 integrantes $\times$ 4 katas), 6 sob Tratamento A (Manual) e 6 sob Tratamento B (Com IA), com representação de todos os 4 katas em ambos os tratamentos. Identificadores genéricos e registros sobrescritos, encontrados na auditoria da base, foram corrigidos por recontagem determinística (Radon) sobre os arquivos finais de cada integrante, 0 inconsistências na versão final (metricas_estaticas.csv, log_trials_consolidado.csv).

4.2 Visualização Gráfica

RQ1 - Time-to-green

Tratamento	N	Mediana (min)	IQR	Wilcoxon
Manual (A)	6	28.19	5.10	W=0,0000; p=0,0625 (unilateral)
Com IA (B)	6	8.14	0.91	r de Rosenthal = 0,7671 (efeito grande)

Redução de mediana de 28,19 para 8,14 min (-71,1%), com dispersão bem menor com IA (IQR 0,91 vs 5,10). Com N=4 pares, o piso matemático do teste unilateral de Wilcoxon é $p = (1/2)^4 = 0,0625$, impossível cravar $p < 0,05$ mesmo com IA vencendo em 100% dos katas (W=0). O efeito é grande ($r=0,7671$) apesar da não-significância formal.




Figura 1 — Time-to-green por tratamento (RQ1).

RQ2 - Taxa de sucesso nos testes

100% de sucesso em todos os 12 trials, nos dois tratamentos, efeito teto (ceiling effect): o time-box de 35 min foi suficiente para corrigir falhas em ambos os grupos. Diferenças pareadas nulas tornam o teste de

Wilcoxon não computável (variância zero); a hipótese não pôde ser testada estatisticamente por essa razão, não por ausência de efeito real.




Figura 2 — Taxa de sucesso por tratamento (RQ2), efeito teto.

RQ3 - Qualidade Estrutural (CC, SLOC/LOC, MI)

Métrica	Trat.	Mediana	IQR	Média±DP	Outliers
CC média	Manual	6.50	1.75	6.67 ± 1.86	1 (K2-Kayque=10.0)
CC média	Com IA	6.00	1.50	6.00 ± 0.89	0
SLOC	Manual	15.00	3.00	16.17 ± 4.12	1 (K2-Kayque=24.0)
MI	Com IA	65.18	26.38	69.41 ± 15.23	0

SLOC mediano idêntico entre tratamentos (15,0 vs 15,0) - a IA não introduziu verbosidade. CC teve menor dispersão com IA (DP 0,89 vs 1,86), sem o outlier presente no manual (K2/Kayque, CC=10, SLOC=24). MI mediano foi maior com IA (65,18 vs 60,05). Densidade CC/SLOC: 0,390 (IA) vs 0,410 (Manual), com desvio quase nulo na IA (0,040 vs 0,100), funções estruturalmente mais homogêneas.

Dimensão	Mediana Manual	Mediana IA	Wilcoxon bilateral)	(p,	Cliff's Delta
CC (RQ3a)	6.75	5.75	W=0.0; p=0.250		-0.1667
SLOC (RQ3b)	15.00	15.00	W=1.5; p=0.750		-0.0278
LOC (RQ3c)	24.00	26.00	W=4.0; p=0.875		+0.1111

MI (RQ3d)	59.17	72.31	W=0.0; p=0.125	+0.1667
-----------	-------	-------	----------------	---------

Nenhuma diferença é estatisticamente significativa a 5% (N=4 pares limita o poder estatístico, piso bicaudal de $p=0,250$ com 1 empate). Ainda assim, MI mostra forte tendência favorável à IA (+13,14 pontos, $p=0,125$) e CC tendência de redução (−1,00, $p=0,250$), ambas na direção esperada pela hipótese, mas sem confirmação formal dado o N pequeno.




Figura 3 — CC, SLOC e MI por tratamento (RQ3).

4.3 Discussão

RQ1 - Tendência forte, não significativa formalmente. Redução de 71% no tempo mediano com IA e efeito grande ($r=0,7671$), mas N=4 katas torna $p<0,05$ matematicamente inatingível no teste unilateral. A hipótese é sustentada na prática, não na formalidade estatística.

RQ2 - Não testável (efeito teto). 100% de sucesso em ambos os tratamentos elimina a variância necessária ao teste; não se pode afirmar nem refutar a hipótese com este desenho, o time-box de 35 min foi generoso o suficiente para ambos os grupos.

RQ3 - Sem significância formal, mas com sinais consistentes. SLOC idêntico (refuta verbosidade por IA); CC com menor dispersão e sem outliers na IA; MI favorece a IA (+13,14, $p=0,125$). Os quatro testes bilaterais não rejeitam H_0 a 5%, mas todos apontam na direção de IA = mais estável e levemente mais manutenível, sem alterar o volume de código.

Ameaças à validade

- N pequeno (4 katas, 12 trials): poder estatístico limitado, pisos de p já discutidos em cada RQ.
- Outlier isolado (K2/Kayque, manual) eleva a variância do grupo Manual em CC e SLOC.
- Toy problems: katas são menores e mais isolados que tarefas de produção real.

5. Conclusão

O assistente de IA reduziu o tempo de resolução em ~71% (RQ1, efeito grande) sem comprometer a corretude (RQ2, 100% em ambos) nem inflar o volume de código (RQ3, SLOC idêntico), com tendência de menor dispersão de complexidade e maior manutenibilidade. Nenhum resultado de RQ3 atingiu significância formal (N=4), mas todos os sinais apontam na mesma direção favorável à IA. Próximo passo natural: repetir o desenho com mais katas/participantes para destravar significância estatística em RQ1 e RQ3.

6. Referências

- BASIL, V. R.; CALDIERA, G.; ROMBACH, H. D. The Goal Question Metric Approach. Encyclopedia of Software Engineering, 1994.
- McCABE, T. J. A Complexity Measure. IEEE Transactions on Software Engineering, 1976.
- WILCOXON, F. Individual comparisons by ranking methods. Biometrics Bulletin, 1945.
- WOHLIN, C. et al. Experimentation in Software Engineering. Springer, 2012.