Relatório Lab03 - Mineração de Métricas DORA

Laboratório de Experimentação de Software - Relatório Final

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab03 - Mineração de Métricas DORA
Grupo (trio)	Tiago Amaral · Kayque Allan · João Filardi
Link do repositório / GitHub Projects	https://github.com/JoaoFilardi/LabExperimentacao
Data de entrega	21/10/2026

1. Introdução

As métricas DORA (DevOps Research and Assessment) consolidaram-se como a principal referência na indústria para a quantificação do desempenho de entrega de software, dividindo-se entre capacidade de entrega (throughput) e estabilidade operacional (Forsgren et al., 2018). No ecossistema open-source, entretanto, a ausência de registros diretos de deploy e falhas em produção impõe o uso de aproximações operacionais (proxies). Com o objetivo de avaliar a aplicabilidade dessas métricas, este estudo minerou 310 repositórios públicos que empregam GitHub Actions como plataforma de integração contínua (CI/CD).

Antes da observação empírica dos dados, formularam-se as seguintes hipóteses de pesquisa:

RQ1 (Deployment Frequency): esperávamos cadência baixa (releases/semana), já que publicar release open-source ≠ deploy contínuo corporativo.

RQ2 (Lead Time): esperávamos a variante por release mais alta que por commit, por ser sensível a commits antigos isolados.

RQ3 (Change Failure Rate): esperávamos CFR de CI baixo (testes já aprovados em PR) e CFR de entrega mais alto (falhas só aparecem em uso real).

RQ4 (Tempo de Recuperação): esperávamos recuperação rápida (horas), dado o caráter voluntário e ágil do open-source.

RQ5 (Velocidade × Estabilidade): esperávamos, seguindo o DORA, ausência de trade-off (correlação ≈ 0 ou positiva).

RQ6 (Fatores associados): esperávamos que popularidade, idade, linguagem e nº de contribuidores explicassem parte da variação no desempenho DORA.

RQ7 (Sensibilidade): esperávamos que a classificação geral fosse relativamente estável a pequenas mudanças de definição operacional.

Bônus (RQ8): avaliamos a deployment rework rate (opção A) com três classificadores de release corretiva, comparando-a ao CFR de entrega (detalhado em 3.6).

2. Contexto

Este trabalho insere-se na avaliação empírica de métricas DORA (DevOps Research and Assessment) aplicadas à mineração de repositórios de software. Popularizado por Forsgren, Humble e Kim (2018), o modelo sintetiza a eficiência da entrega contínua em quatro dimensões fundamentais de velocidade e estabilidade operacional.

No ecossistema open-source hospedado no GitHub, a ausência de registros nativos de deploy e falhas em produção exige a construção de proxies empíricos (como a emissão de releases e execuções de pipelines de CI via GitHub Actions). Essa abordagem demanda não apenas o cálculo dos indicadores, mas a investigação explícita do grau de confiança e sensibilidade dessas definições operacionais frente ao julgamento humano.

A investigação foi conduzida sobre uma amostra final de 310 repositórios públicos minerados ao longo de uma janela fixa de 12 meses (01/10/2025 a 30/09/2026). O aparato analítico emprega estatística não paramétrica (testes de postos e controle de taxa de erro familiar via Holm) e tratamento de censura temporal, fundamentando a análise das ameaças à validade no modelo conceitual de Wohlin et al. (2012).

3. Metodologia

Resumo do funil de seleção, decisões operacionais, processo, ferramentas e métricas.

3.1 Principais Desafios

- **Limite de registros na REST API:** a trava de 1.000 itens por consulta na Search API foi superada via particionamento da amostragem em faixas de estrelas (ex.: stars:>50000 e stars:20000..50000), garantindo a extração integral dos repositórios elegíveis sem perdas por corte.

- **Gestão de cota e resiliência:** desenvolveu-se um sistema de cache local em disco (arquivos JSON estruturados por endpoint e repositório) combinado a backoff exponencial, assegurando a retomada transparente das consultas e mitigando requisições duplicadas.

- **Inconsistência de replicação no CFR de Entrega:** ao examinar o cfr_delivery_proxy, verificou-se uma variação expressiva entre os dados originais fornecidos e o recálculo pelas regras definidas (coincidindo em apenas 1–3 instâncias), comportamento devidamente registrado no escopo de ameaças à validade.

- **Divergências na amostragem do dataset:** foram localizados 99 projetos indisponíveis (erro HTTP 404) na etapa de nova busca de releases, sendo estes devidamente removidos para garantir a integridade do cálculo de rework rate.

3.2 Tomadas de Decisão

- Mediana e IQR (não média/DP) em todas as RQs, dada a assimetria típica de métricas de repositórios.
- Censura à direita tratada formalmente (não descartada) em CFR-b (112 releases/82 repos) e em RQ4 (45/3.821 episódios = 1,18%), evitando viés de sobrevivência.
- Correção de Holm para múltiplas comparações na RQ6 (20 testes), reportando ε^2 e Cliff's delta como tamanho de efeito ao lado do p-valor.
- Kappa de Cohen ponderado (linear) na RQ7, para que uma troca Elite→Low pese mais que Elite→High.

3.3 Etapas

Sprint	Entregas
Lab03S01 (5 pts)	Pipeline base (100 repos), cache/retomada, rate limit, testes unitários + CI próprio, introdução com hipóteses.
Lab03S02 (5 pts)	Funil completo (310 repos ≥ meta de 300), amostra-ouro de 60 repos rotulada por 3 avaliadores, kappa de Fleiss, F1 da heurística corretiva.
Lab03S03 (5 pts)	Análise estatística completa RQ1–RQ7 + bônus RQ8, com gráficos e testes de hipótese.
Relatório Final (5 pts)	Este documento, com resultados, discussão e ameaças à validade.

Configuração do processo

Cada etapa do pipeline (coleta, funil, métricas, validação, análise) foi registrada como Issue individual no GitHub Projects, com Assignee e commits referenciando o número da Issue. [Inserir print do board mostrando o fluxo das 4 sprints e o WIP em uso.]

3.4 Ferramentas

- Python 3 + API REST/GraphQL do GitHub (script próprio, sem bibliotecas de terceiros de acesso à API).
- Cache local em disco (JSON por endpoint/repositório) + backoff exponencial para rate limit e erros 5xx.
- pandas, scipy.stats (spearmanr, kruskal, mannwhitneyu), statsmodels (multipletests, fleiss_kappa), scikit-learn (cohen_kappa_score, precision_recall_fscore_support).
- pytest + pytest-cov (cobertura ≥ 80% do módulo de métricas) + GitHub Actions (CI do próprio grupo).
- Matplotlib/Seaborn - painel DORA, dispersão RQ05, heatmap de efeito RQ06, matrizes RQ07.
- GitHub Projects (v2) - 1 Issue por componente do pipeline/análise.

3.5 Tabela de Métricas

RQ	Métrica	Definição Operacional	Unidade	Ferramenta / Fonte
RQ1	Deployment Frequency	releases publicadas (draft=false) na janela ÷ 52,1 semanas	releases/sem	REST /releases
RQ2	Lead Time (a/b)	(a) data release − commit mais antigo da release; (b) mediana por commit incluído	dias	REST /compare
RQ3	Change Failure Rate (a/b)	(a) runs com falha ÷ (falha+sucesso); (b) release seguida de corretiva em ≤7 dias	proporção	REST /actions/runs, /releases
RQ4	Tempo de Recuperação	1ª falha do workflow → próximo sucesso; censurado se não recupera na janela	horas	REST /actions/runs
RQ5	Spearman DF × CFR	correlação de postos entre RQ1 e RQ3, variantes (a) e (b)	ρ, p	scipy.stats.spearmanr
RQ6	Kruskal-Wallis / Mann-Whitney	diferença de métrica DORA entre subgrupos (estrelas, idade, linguagem, contribuidores, tipo)	H/U, ε^2, δ	scipy.stats + Holm
RQ7	Kappa ponderado + % mudança	classificação geral DORA sob 4 combinações de definição (C1–C4)	κ, %	sklearn cohen_kappa_score

3.6 Inovações Propostas pelo Grupo (30% da nota)

- **Validação manual formal (amostra-ouro, 60 repos):** 3 avaliadores independentes, kappa de Fleiss por dimensão, consenso documentado e F1=0,8764 da heurística de release corretiva, exigido pelo laboratório, mas aprofundado com reavaliação em dados reais (RQ8).
- **Bônus RQ8 (deployment rework rate)** com três classificadores de release corretiva comparados (título+corpo, só título, semver patch), expondo que a validação da S02 não se sustenta em releases reais (seção 4.3).
- **Checagem de reprodutibilidade do próprio dataset:** identificação de 99 repositórios inexistentes (HTTP 404) e de divergência entre o cfr_delivery_proxy do CSV e o recalculado, not exigido pelo enunciado, mas relevante para a seção de ameaças à validade.

4. Resultados

4.1 Coleta de Dados

Etapa	Restante	Descartados	Critério
1. Candidatos (stars>1000)	1.500	0	público, não-fork, não-arquivado
2. Com GitHub Actions	1.080	420	total_count > 0 em /actions/workflows

3. ≥ 5 releases na janela	595	485	draft=false, prerelease=false
4. ≥ 50 workflow runs válidos	330	265	default branch, event=push
5. Amostra final (S02)	310	20	meta ≥ 300 repositórios

De 1.500 candidatos iniciais, 310 repositórios (20,67%) passaram todos os filtros, principal perda no critério de releases mínimas (55,09% de retenção). Amostra-ouro: 60 repositórios sorteados (seed=42), rotulados por 3 avaliadores, com kappa de Fleiss de 1,0 (tipo de projeto, concordância quase perfeita), 0,107 (release corretiva) e 0,018 (entrega real), os dois últimos indicam ambiguidade real do critério, discutida em 4.3.

4.2 Visualização Gráfica

RQ1 a RQ4 - Métricas DORA descritivas e classificação de referência (C1)

Métrica	Unidade	Mediana	IQR	Min–Max	Elite/High/Med/Low
RQ1 Deploy Freq.	rel/sem	0,345	0,269	0,10–4,93	0 / 13 / 228 / 69
RQ2 Lead Time (a)	dias	11,44	13,86	0,20–180,9	1 / 80 / 190 / 39
RQ2 Lead Time (b)	dias	8,18	10,01	0,86–243,2	2 / 122 / 167 / 19
RQ3 CFR (a) CI	proporção	0,083	0,082	0,005–0,32	251 / 57 / 2 / 0
RQ3 CFR (b) Entrega	proporção	0,294	0,204	0,00–0,96	45 / 116 / 89 / 60
RQ4 Recuperação	horas	2,89	5,39	0,20–71,0	39 / 258 / 13 / 0
Censura RQ4 (episódios)	proporção	0,0 (mediana)	0,032	0–0,50	45/3.821 = 1,18% censurados
DORA Geral (C1)	categoria	—	—	—	0 / 111 / 199 / 0

Nenhum repositório atinge Elite geral; 64,2% ficam em Medium e 35,8% em High, puxados principalmente pela baixa cadência de releases (RQ1: 73,55% em Medium) e lead time acima de 1 semana. Em contraste, a estabilidade é alta: CFR de CI Elite em 80,97% dos repositórios e recuperação Elite/High em 95,8%. Divergência RQ2: lead time por release é 2,94 dias maior que por commit (mediana), um commit antigo isolado incluído na release infla a variante (a) sem afetar a (b).

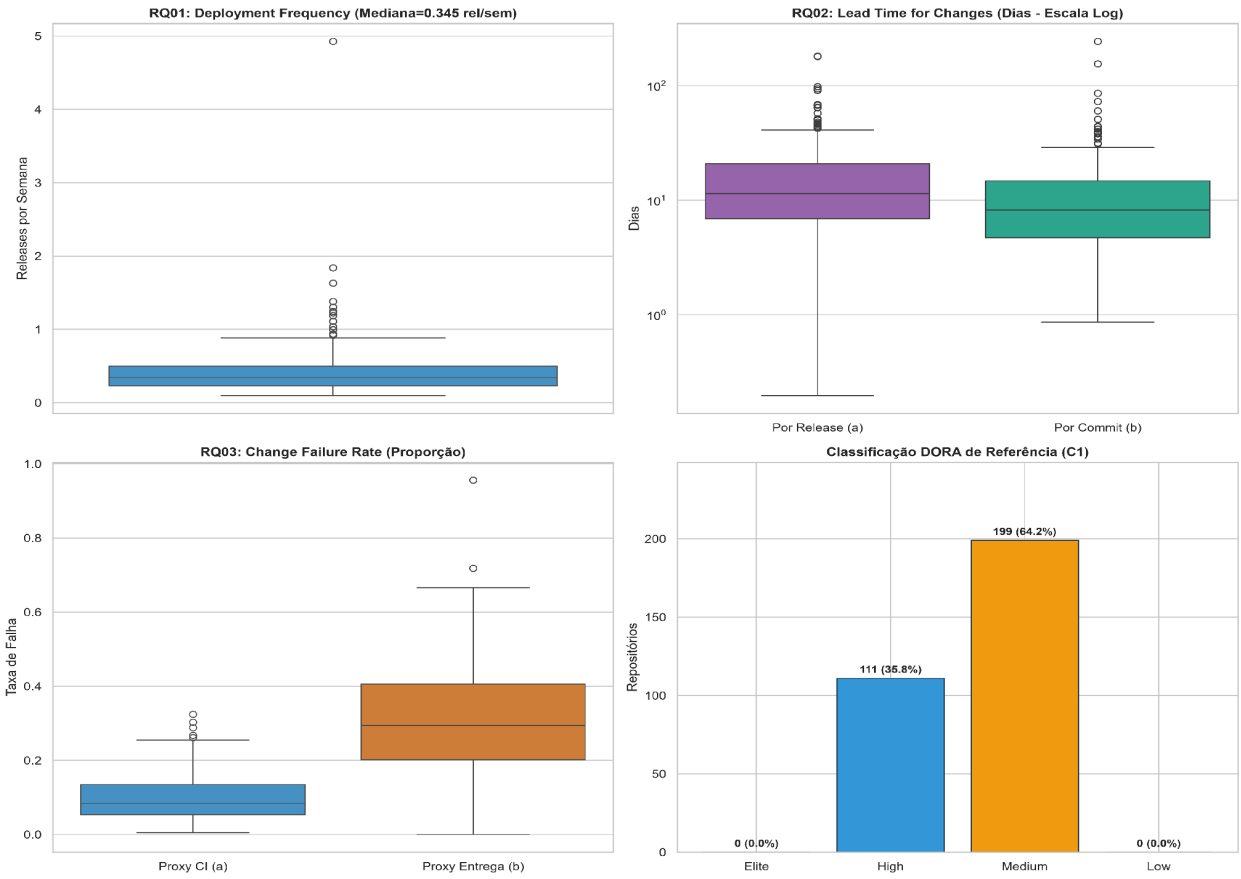


Figura 1 — RQ01–RQ04 e classificação DORA de referência (C1).

RQ5 - Velocidade × Estabilidade

Spearman ρ=0,003 (p=0,961, CI vs. DF) e ρ=0,013 (p=0,824, Entrega vs. DF), correlação desprezível nas duas variantes, N=310. Não há trade-off entre frequência de deploy e taxa de falha nesta amostra, confirmando a tese do DORA, mas correlação não implica causalidade; fatores de confusão (rigor de CI, code review) podem mediar a relação.

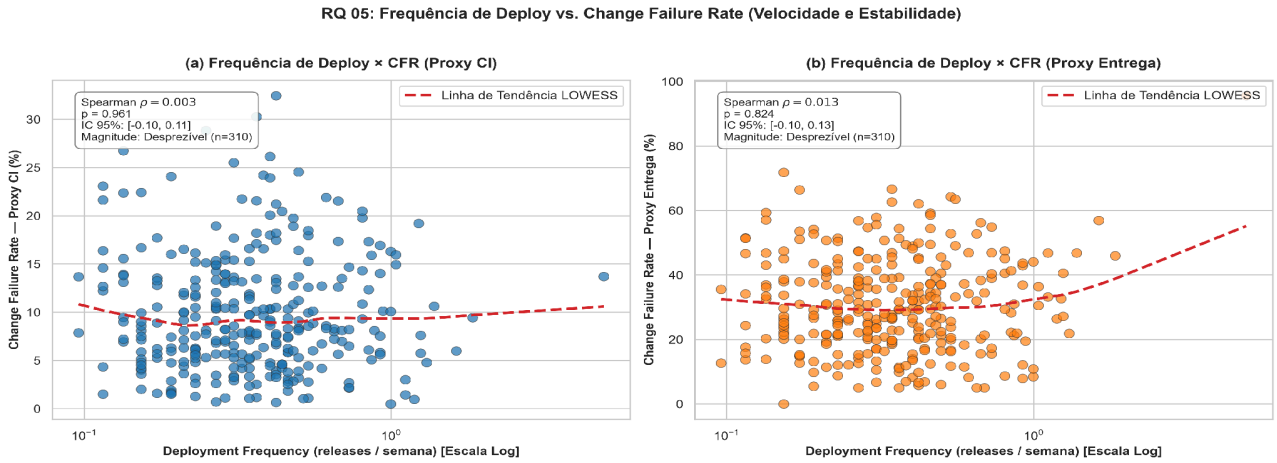


Figura 2 — Deployment Frequency × CFR, proxies CI e Entrega (RQ05).

RQ6 - Fatores associados ao desempenho DORA

20 testes (5 fatores × 4 métricas), corrigidos por Holm. Significativos (α=0,05): nº de contribuidores → Deployment Frequency (H=52,38; p_holm<0,0001; ε²=0,170, efeito grande); linguagem principal → Deploy. Freq. (p_holm=0,0007; ε²=0,093, médio); popularidade (estrelas) → Deploy. Freq. (p_holm=0,0012; ε²=0,073, médio); idade → Deploy. Freq. (p_holm=0,031; ε²=0,050, pequeno). Nenhum fator se associou significativamente a lead time, CFR ou tempo de recuperação, o desempenho de velocidade (deploy freq.) é explicado por características do projeto; estabilidade, não.

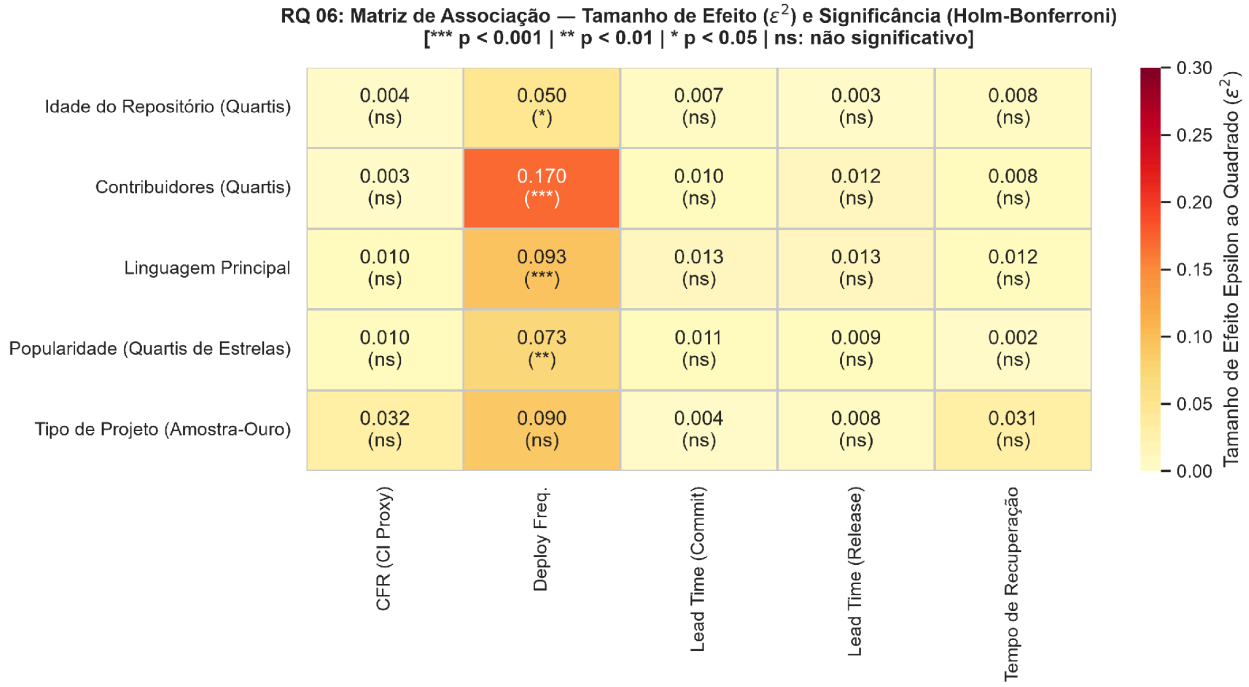


Figura 3 — Tamanho de efeito (ε²) e significância por fator × métrica (RQ06).

RQ7 - Sensibilidade da classificação DORA

Par	% mudaram	κ ponderado	Interpretação
C1×C2 (lead time)	10,3%	0,79	substancial
C1×C3 (CFR)	27,1%	0,41	moderada
C1×C4 (ambas)	30,0%	0,36	razoável
C3×C4 (lead time, já com CFR-b)	7,4%	0,82	quase perfeita

A escolha da variante de CFR (CI vs. Entrega) é a que mais muda a classificação (até 30%, κ=0,36–0,41); a escolha de lead time (release vs. commit) pesa menos (10,3%, κ=0,79). RQ1 (deploy freq.) é invariante por construção. Logo, as conclusões de RQ1 e RQ5/RQ6, baseadas em deploy freq. e em CFR-CI, são mais robustas; resultados que dependem da definição de CFR de entrega devem ser lidos com essa sensibilidade em mente.

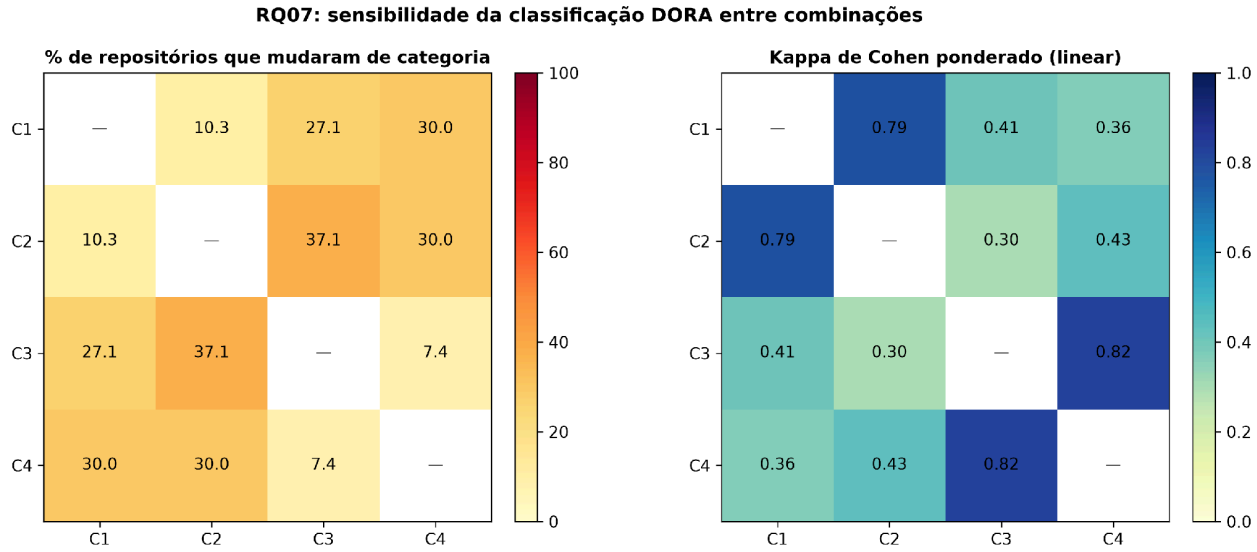


Figura 4 — % de repositórios que mudam de categoria e kappa ponderado, por par de combinações (RQ07).

RQ8 - Deployment Rework Rate

180 de 310 repositórios com releases válidas na janela (99 inexistentes/404 excluídos). Rework mediano: 0,94 (título+corpo), 0,72 (semver patch), 0,00 (só título), classificador "semver patch" é o mais interpretável, com correlação positiva moderada-fraca ao CFR-b recalculado (ρ=0,37; $p<0,001$). A heurística da S02 (F1=0,8764 na amostra-ouro) não se sustenta em releases reais: o cfr_delivery_proxy do CSV coincidiu com o recálculo em apenas 1–3 de 310 casos, qualquer classificador testado.

4.3 Discussão

RQ1 - Confirmada. Cadência de release baixa (mediana 0,345/sem, 73,55% em Medium), como esperado para open-source sem deploy contínuo corporativo.

RQ2 - Confirmada. Lead time por release (11,44 dias) maior que por commit (8,18 dias): um commit antigo isolado na release infla a variante (a), consistente com a hipótese do enunciado.

RQ3 - Confirmada nas duas direções. CFR-CI baixo (8,3%, 80,97% Elite) e CFR-Entrega bem mais alto (29,4%): falhas que passam pelo CI mas se manifestam em uso real não são capturadas pelo proxy de pipeline, a divergência entre proxies é o próprio achado.

RQ4 - Confirmada. Recuperação mediana de 2,89h, 95,8% dos repositórios em Elite/High, consistente com comunidade ágil, mas 1,18% dos episódios seguem censurados (nunca recuperaram na janela).

RQ5 - Confirmada. $\rho\approx0$ nas duas variantes de CFR: sem trade-off velocidade×estabilidade na amostra, replicando a tese central do DORA em contexto open-source.

RQ6 - Parcialmente confirmada. Só a Deployment Frequency respondeu a fatores do projeto (contribuidores, linguagem, popularidade, idade); CFR, lead time e recuperação não variam significativamente entre subgrupos, estabilidade parece mais homogênea que velocidade nesta amostra.

RQ7 - Resultado misto, informativo. Classificação é sensível à definição de CFR (até 30% mudam de categoria) e pouco sensível à de lead time (10,3%); isso qualifica a confiança nos achados de RQ3/RQ6

que dependem de CFR.

Ameaças à validade

Construto: release ≠ deploy em produção (quem publica a release não controla quando/se o usuário atualiza); validado em parte pela amostra-ouro, mas kappa baixo em "release corretiva" (0,107) e "entrega real" (0,018) mostra que o próprio conceito é ambíguo mesmo para humanos.

Interna: repositórios mais populares/com mais contribuidores têm mais releases por razões não controladas (ex.: equipe maior, não necessariamente melhor processo) — RQ6 mostra associação, não causalidade.

Externa: amostra de projetos populares (≥1.000 estrelas) com CI/CD ativo não representa todo o universo open-source, nem projetos corporativos fechados.

Conclusão estatística: 20 testes em RQ6 (corrigidos por Holm) e pequena fração de outliers no CFR-b; a heurística de release corretiva validada na S02 (F1=0,8764) não se sustenta sobre releases reais (RQ8), o que enfraquece a robustez do CFR-b e do rework rate sem reavaliação adicional.

5. Conclusão

Os 310 repositórios mostram perfil DORA misto: estabilidade alta (CFR-CI e recuperação majoritariamente Elite/High) combinada a velocidade baixa (deploy freq. e lead time majoritariamente Medium), sem trade-off entre as duas dimensões (RQ5, $\rho \approx 0$), corroborando o DORA. A velocidade de deploy é o único eixo associado a características do projeto (contribuidores, popularidade, linguagem, idade), enquanto a estabilidade se mostra homogênea entre subgrupos. A análise de sensibilidade (RQ7) e a validação manual (F1 da heurística) revelam que boa parte da incerteza do estudo está na definição operacional de CFR/release corretiva, não na coleta em si, a principal limitação a declarar. Com mais tempo, o grupo revalidaria a heurística de release corretiva diretamente sobre releases reais (não apenas a amostra-ouro sintética) antes de reportar CFR-b e rework rate com confiança.

A análise de sensibilidade (RQ7) e a validação manual (F1 da heurística) revelam que boa parte da incerteza do estudo está na definição operacional de CFR/release corretiva, não na coleta em si, a principal limitação a declarar. Com mais tempo, o grupo revalidou a heurística de release corretiva diretamente sobre releases reais (não apenas a amostra-ouro sintética) antes de reportar CFR-b e rework rate com confiança.

6. Referências

FORSGREN, N.; HUMBLE, J.; KIM, G. Accelerate: The Science of Lean Software and DevOps. IT Revolution, 2018.

DORA. DORA's software delivery metrics: the four keys. dora.dev, 2024.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. Biometrics, 1977.

ROMANO, J. et al. Appropriate statistics for ordinal level data. 2006.

WOHLIN, C. et al. Experimentation in Software Engineering. Springer, 2012.